Оглавление

В	Введение			
1	Ана	литиче	еский раздел	4
	1.1 Формализация цели		ализация цели	4
	1.2	Понят	тие процесса реального времени	4
			иние работы RT Scheduler	4
	1.4	Структуры ядра		5
		1.4.1	task_struct	5
		1.4.2	sched_info	11
		1.4.3	sched_rt_entity	12
	1.5 Способы определения принадлежности задачи к группе задач реального в			
		мени	· · · · · · · · · · · · · · · · · · ·	13
		1.5.1	Функция rt prio	13
		1.5.2	Функция rt task	13
		1.5.3	Функция task_is_realtime	14
2	Конструкторский раздел			16
	2.1	2.1 Диаграмма вариантов использования		
3	Технологический раздел			17
	3.1 Выбор и обоснование языка программирования и среды разработки		17	
	3.2	6.2 Пример кода, да?		17
4	Исследовательский раздел			18
	4.1	Бла-бл	па	18
3 <i>A</i>	КЛЮ	очені	ИЕ	19
Cl	пис	ОК ИС	ПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	20
П	ри па	эжги	ALE 1	21

ВВЕДЕНИЕ

*** Линух — сложная система со своим видением планирования процессов на выполнение и всё такое.

1. Аналитический раздел

В данном разделе...

1.1 Формализация цели

Цель работы – разработать загружаемый модуль ядра для мониторинга приоритетов, времени выполнения и простоя процессов на ОС Linux и проанализировать с использованием данного модуля воспроизведение аудиофайлов и видеофайлов.

Для достижения поставленной цели потребуется:

- 1) проанализировать структуры ядра, позволяющие определить приоритет, время выполнения и простоя процессов;
- 2) проанализировать способы доступа к выбранным структурам ядра;
- 3) проанализировать методы передачи информации из модуля ядра в пространство пользователя;
- 4) спроектировать и реализовать загружаемый модуль ядра;
- 5) проанализировать с использованием реализованного модуля воспроизведение аудиофайлов и видеофайлов.

1.2 Понятие процесса реального времени

Процесс реального времени — это процесс, который имеет приоритет над обычными процессами. В Linux планирование процессов реального времени возложено на так называемый RT Scheduler (Real Time Scheduler — планировщик реального времени), а обычные процессы обрабатываются с использованием CFS Scheduler (Completely Fair Scheduler — совершенно честный планировщик). Работа данных планировщиков строится на работе с группами процессов, которые расположены в очередях, которые, в свою очередь, организованы в дерево. [1]

1.3 Описание работы RT Scheduler

Проблема планирования в режиме реального времени заключается в том, что группы процессов должны полагаться на постоянство объема полосы пропускания (например, времени исполнения). Для планирования нескольких групп задач в реальном времени может потребоваться назначение, так называемого, гарантированного доступного времени исполнения. [2]

В качестве решения поставленной проблемы доступное процессорное время делится посредством указания того, сколько времени на исполнение

даётся на указанный период. Данное время выделяется для каждой группы процессов реального времени, причём каждая группа может исполнятся только в свое выделенное время. [2]

Время, не выделенное группам реального времени или неиспользованное ими, будет выделено задачами с обычным приоритетом (SCHED_OTHER). [2]

Для примера можно рассмотреть следующую задачу: рендерер реального времени с фиксированным количеством кадров должен выдавать 25 кадров в секунду, что дает период 0.04 секунды на каждый кадр. Если перед рендерером также стоит параллельная задача проигрывания музыки и ответа на ввод, оставляя около 80% доступного процессорного времени, предназначенного для графики, то для этой группы можно выделить время выполнения $0.8 \cdot 0.04 = 0.032$ секунды.

Таким образом, графическая группа будет иметь период 0.04 секунды с ограничением времени выполнения 0.032 секунды. Если аудиопотоку необходимо заполнять буфер DMA (Direct Memory Access, прямой доступ к памяти) каждые 0.005 секунд, но для этого требуется около 3% времени процессора, ему может быть выделено время выполнения $0.03 \cdot 0.005 = 0.00015$ секунд. Таким образом, данная группа может быть запланирована с периодом 0.005 секунд с временем выполнения 0.00015 секунд.

Оставшееся процессорное время будет использовано для ввода данных пользователем и других задач.

Однако на текущий момент приведенный выше пример еще не реализован полностью в силу того, что отсутствует реализация планировщика EDF (Erlienst Deadline First scheduling, алгоритм планирования по ближайшему сроку завершения) для использования неоднородных периодов. [2]

1.4 Структуры ядра

Современные операционные системы предоставляют пользователю фундаментальные концепции, такие как, файл или процесс. [3]

С использованием документации представляется возможность получить доступ к данным концепциям и изучить работу системы изнутри.

1.4.1 task_struct

Процесс состоит из нескольких компонентов [3]:

• стек процесса;

- регистры процессора, в которые загружены ключевые переменные (зависит от архитектуры);
- адресное пространство;
- ресурсы: дескрипторы открытых файлов, ожидающие обработки сигналы;
- управляющие структуры ядра ОС.

Структура в ядре Linux, соответствующая каждому процессу, – task_struct. Она определена в файле include/linux/sched.h. Все процессы существующие в системе процессы объединены в кольцевой список. [3]

Стоит отметить, что данная структура занимает в памяти порядка 1.7 килобайт.

Поля структуры содержат информацию о процессе, которую можно поделить на несколько категорий [3]:

- поля, отвечающие за общую информацию о процессе (PID, exit_code, PPID);
- поля, востребованные планировщиком задач (prio, static prio, timeslice);
- поля, связанные с безопасностью (uid, gid).

Структура task_struct для Linux v5.16rc8 представлена в приложении (см. Приложение 1).

Далее будут отмечены наиболее информативные в проводимой работе поля данной структуры и их назначение.

pid (Process Identifier) – уникальный идентификатор процесса. Каждый процесс в операционной системе имеет свой уникальный идентификатор, по которому можно получить информацию об этом процессе, а также направить ему управляющий сигнал или завершить [4].

prio, static_prio, normal_prio, rt_priority – приоритеты процесса.

prio — это значение, которое использует планировщик задач при выборе процесса. Чем ниже значение данной переменное, тем выше приоритет процесса (может принимать значения от 0 до 139, то есть MAX_PRIO, значение которого вычисляется с использованием переменной MAX_RT_PRIO со значением 100) [5]. Также данный приоритет может быть поделён на два интервала:

- от 0 до 99 процесс реального времени;
- от 100 до 139 обычный процесс.

Также определены функции определения приоритета процесса, которые приведены в листинге 1.

Листинг 1: Функции определения приоритета процесса, определенные в /kernel/sched.c

```
#include "sched idletask.c"
    #include "sched fair.c"
    #include "sched rt.c"
    #ifdef CONFIG SCHED DEBUG
4
    #include "sched debug.c"
5
    #endif
     /*
8
     * normal prio - return the priority that is based on
      \hookrightarrow the static prio
     */
    static inline int normal prio(struct task struct *p) //
11
     \rightarrow NORMAL PRIO function, return static priority value
12
         return p->static prio;
13
     }
15
     /*
16
      * Calculate the expected normal priority: i.e. priority
17
     * without taking RT-inheritance into account. Might be
     * boosted by interactivity modifiers. Changes upon fork,
     * setprio syscalls, and whenever the interactivity
20
     * estimator recalculates.
21
     * /
22
    static inline int normal prio(struct task struct *p) //
     \hookrightarrow NORMAL PRIO function
24
         int prio;
25
         if (task has rt policy(p)) // The task has rt policy
             function, the determination process is a real-time
          → process, if the real-time process, returns 1,
          \rightarrow otherwise returns 0
```

```
prio = MAX RT PRIO-1 - p->rt priority; //
28
              \rightarrow process is real-time process, and the PRIO
                value is related to the real-time priority
                value: PRIO = MAX RT PRIO -1 - P-> rt priority
        else
29
             prio = normal prio(p); // The process is a
30
              \rightarrow non-real-time process, then the PRIO value is
                 a static priority value, that is, PRIO = P->
                 static prio
        return prio;
31
    }
32
33
    /*
     * Calculate the current priority, i.e. the priority
35
     * taken into account by the scheduler. This value might
36
     * be boosted by RT tasks, or might be boosted by
37
     * interactivity modifiers. Will be RT if the task got
     * RT-boosted. If not then it returns p->normal prio.
     */
40
    static int effective prio(struct task struct *p) // The
41
       Effective Prio function, the effective priority of the
        calculation process, the PRIO value, this value is the
        priority value used by the final scheduler
42
        p->normal prio = normal prio(p); // Calculate the
43
         \rightarrow value of Normal PRIO
         /*
44
         ^{\star} If we are RT tasks or we were boosted to RT
          → priority,
          * keep the priority unchanged. Otherwise, update
46
          → priority
          * to the normal priority:
47
          */
48
         if (!rt prio(p->prio))
49
             return p->normal prio; // If the process is a
50
              → non-real-time process, return normal prio
               value, at this time Normal Prio = Static Prio
         return p->prio; // Otherwise, the return value is
             constant, still PRIO value, at this time, PRIO =
            MAX RT PRIO -1 - P-> RT Priority
    }
52
```

```
53
   54
   void set user nice(struct task struct *p, long nice)
55
    {
56
57
       p->prio = effective prio(p); // In the function
58
          set user nice, call the Effective Prio function to
          set the process's PRIO value.
59
       . . .
    }
60
```

Из предоставленного листинга видно, что для процессов реального времени значение приоритета определяется с использованием поля prio, а в ином случае — static_prio.

static_prio не изменяется ядром при работе планировщика, однако оно может быть изменено с использованием пользовательского приоритета пісе. Макрос для изменения данного приоритета предоставлен в листинге 2.

Листинг 2: Макрос для изменения static_prio.

```
/*
1
     * Convert user-nice values [ -20 ... 0 ... 19 ]
2
     * to static priority [ MAX RT PRIO..MAX PRIO-1 ],
     * and back.
     * /
5
    #define NICE TO PRIO(nice)
                                  (MAX RT PRIO + (nice) + 20)
6
    #define PRIO TO NICE(prio) ((prio) - MAX RT PRIO - 20)
7
    #define TASK NICE(p)
PRIO TO NICE((p)->static prio)
10
     * 'User priority' is the nice value converted to
11
      \rightarrow something we
     * can work with better when scaling various scheduler
12
      → parameters,
     * it's a [ 0 ... 39 ] range.
13
     */
14
    #define USER PRIO(p)
                                ((p)-MAX RT PRIO)
15
    #define TASK USER PRIO(p)
                                USER PRIO((p)->static prio)
```

```
#define MAX_USER_PRIO (USER_PRIO(MAX_PRIO))

/ *** /
p->static_prio = NICE_TO_PRIO(nice);
```

Таким образом, значение статического приоритета может быть изменено с использованием вызова макроса NICE_TO_PRIO(nice).

normal_prio зависит от статического приоритета и политики планировщика задач. Для процессов не реального времени данное значение равняется значению статического приоритета static_prio. Для процессов реального времени данное значение равняется значению, вычисленному с использованием максимального значения приоритета процесса реального времени и, непосредственно, его rt_priority. Функция вычисления нормального приоритета предоставлена в листинге 3.

Листинг 3: Функция вычисления нормального приоритета.

```
static inline int normal prio(struct task struct *p) //
      \hookrightarrow NORMAL PRIO function
2
         int prio;
3
         if (task has rt policy(p)) // The task has rt policy
         \hookrightarrow function, the determination process is a real-time
         → process, if the real-time process, returns 1,
          \rightarrow otherwise returns 0
             prio = MAX RT PRIO-1 - p->rt priority; //
              → process is real-time process, and the PRIO
              → value is related to the real-time priority
                value: PRIO = MAX RT PRIO -1 - P-> rt priority
         else
             prio = normal prio(p); // The process is a
              \scriptscriptstyle
ightarrow non-real-time process, then the PRIO value is
              \rightarrow a static priority value, that is, PRIO = P->

    static prio

         return prio;
```

10 }

Важно отметить факт того, что, чем больше значение rt_priority, тем выше приоритет процесса.

1.4.2 sched_info

sched_info – структура, которая предоставляет информацию о планировании процесса:

- количество запусков процесса на исполнение центральным процессором;
- количество времени, проведенного в ожидании на исполнение;
- время последнего запуска процесса на исполнение центральным процессором;
- время последнего добавления процесса в очередь на исполнение. Данная структура предоставлена в листинге 5.

Листинг 4: Структура sched info.

```
struct sched info {
    #ifdef CONFIG SCHED INFO
        /* Cumulative counters: */
3
4
        /* # of times we have run on this CPU: */
5
        unsigned long
                                   pcount;
        /* Time spent waiting on a runqueue: */
8
        unsigned long long run delay;
10
        /* Timestamps: */
12
        /* When did we last run on a CPU? */
13
                                    last arrival;
        unsigned long long
14
        /* When were we last queued to run? */
        unsigned long long
                                   last queued;
17
18
    #endif /* CONFIG SCHED INFO */
19
    };
20
```

utime — это время, проведенное в режиме пользователя и затраченное на запуск команд. Данное значение включает в себя только время, затраченное центральным процессором, и не включает в себя время, проведенное процессом в очереди на исполнение.

stime — это время процессора, затраченное на выполнение системных вызовов при исполнении процесса.

1.4.3 sched rt entity

sched_rt_entity — это структура, используемая для группового планирования процессов реального времени, которое включает в себя деревья групп и их очередей. Данное решение позволяет определять выделяемую производительность процессора для определенных групп процессов.

Структура sched rt entity предоставлена в листинге 5.

Листинг 5: Структура sched_rt_entity.

```
struct sched rt entity {
1
        struct list head
                               run list;
2
                                 timeout;
        unsigned long
3
        unsigned long
                                 watchdog stamp;
        unsigned int
                                time slice;
5
        unsigned short
                                 on rq;
6
        unsigned short
                                  on list;
        struct sched rt entity
                                      *back;
9
    #ifdef CONFIG RT GROUP SCHED
10
        struct sched rt entity
                                      *parent;
11
        /* rq on which this entity is (to be) queued: */
12
        struct rt rq
                                 *rt rq;
13
        /* rq "owned" by this entity/group: */
14
        struct rt rq
                                 *my q;
15
    #endif
16
    } randomize layout;
```

В данной структуре поле parent указывает на процесс более высокого уровня в дереве. rt_rq — это очередь, в которой процесс находится, а my_q — это очередь дочерних процессов.

Поле timeout изменяется так называемым watchdog таймером и используется для проверки того, что процесс не занимает процессор дольше, чем это задано в RLIMIT_RTTIME.

1.5 Способы определения принадлежности задачи к группе задач реального времени

В файле /include/linux/sched/rt.h определены функции, позволяющие определить, является ли процесс задачей реального времени.

1.5.1 Функция rt prio

Реализация данной функции приведена в листинге 6.

Листинг 6: Функция rt prio.

```
static inline int rt_prio(int prio)

{
    if (unlikely(prio < MAX_RT_PRIO))
        return 1;
    return 0;
}</pre>
```

Представленная функция определяет, является ли процесс задачей реального времени, с использованием значения приоритета. Приоритет задачи сравнивается с максимальным значением приоритета для задачи реального времени. В случае, если условие истинно, процесс относится к задачам реального времени и возвращается единица.

Важно отметить, что макрос unlikely в данном случае применяется для оптимизации скорости выполнения сравнения.

1.5.2 Функция rt_task

Реализация данной функции приведена в листинге 7.

Листинг 7: Функция rt_task.

```
static inline int rt_task(struct task_struct *p)
{
    return rt_prio(p->prio);
}
```

rt_task является оберточной функцией для вызова функции rt_prio. Возвращает единицу в том случае, если процесс является задачей реального времени.

1.5.3 Функция task_is_realtime

Реализация данной функции приведена в листинге 8.

Листинг 8: Функция task_is_realtime.

task_is_realtime анализирует политику планировщика из преданной структуры task_struct. SCHED_FIFO и SCHED_RR являются, так называемыми, политиками реального времени.

SCHED_FIFO – это политика панирования реального времени "первый вошел, первый вышел". Данный алгоритм планирования не использует интервалов времени, а процесс выполняется до завершения, если он не заблокирован запросом ввода-вывода, вытеснен высокоприоритетным процессом, или он добровольно не отказывается от процессора. [6]

Следует обратить внимание на то, что процесс SCHED_FIFO, вытесненный другим процессом с более высоким приоритетом, остается во граве списка с его приоритетом и возобновит выполнение, как только все процессы с более высоким приоритетом будут вновь заблокированы. Также, когда процесс SCHED_FIFO готов к выполнению (например, после пробуждения от операции блокировки), он будет вставлен в конец списка с его приоритетом. [6]

Вызов sched_setscheduler или sched_setparam поставит процесс SCHED_FIFO в начало списка. Как следствие, это может вытеснить исполняющийся в данный момент процесс, если его приоритет такой же, как и у исполняющегося процесса. [6]

SCHED_RR – это циклическая (Round-Robin) политика планирования реального времени. Она похожа на SCHED_FIFO с той лишь разницей, что процессу SCHED_RR разрешено работать как максимум время кванта. Если процесс SCHED_RR исчерпывает свой квант времени, он помещается в конец списка с его приоритетом. [6]

Процесс SCHED_RR, который был вытеснен процессом с более высоким приоритетом, завершит оставшуюся часть своего кванта времени после возобновления выполнения. [6]

Планировщик класса SCHED_DEADLINE реализует алгоритм EDF (Earliest Deadline First), который основан на идее выбора для выполнения из очереди ожидающих процессов задачи, наиболее близкой к истечению крайнего расчетного времени. SCHED_DEADLINE поддерживает обеспечение работы процессов, требующих выполнения операций в режиме реального времени, предоставляя для подобных задач гарантированное время выполнения, независимо от общего количества обслуживаемых процессов, и реализуя возможность резервирования пропускной способности процессора для процессов. [7]

Как видно из реализации функции, оставшиеся политики планировщика задач не относятся к алгоритмам планирования реального времени.

Вывод

В разделе...

2. Конструкторский раздел

В данном разделе...

2.1 Диаграмма вариантов использования

На рисунках 2.1–2.2 предоставлены примеры картинок.



Рис. 2.1: Какой-то пример.

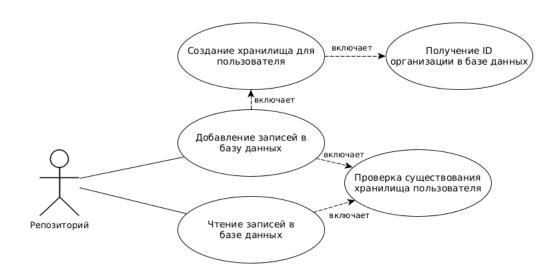


Рис. 2.2: Вторая часть какого-то примера.

Вывод

В разделе...

3. Технологический раздел

В данном разделе...

3.1 Выбор и обоснование языка программирования и среды разработки

При написании программного продукта был использован язык программирования...

Данный выбор обусловлен следующими факторами:

- бла,
- бла,

3.2 Пример кода, да?

Вывод

В качестве средств реализации были выбраны...

В разделе были предоставлены сведения о...

Была рассмотрена...

4. Исследовательский раздел

В данном разделе...

4.1 Бла-бла

Мы такие умные, куча исследований...

Вывод

В разделе...

ЗАКЛЮЧЕНИЕ

Во время выполнения курсового проекта были достигнуты поставленные задачи:

- хоп,
- хоп,
- хоп,
- хоп,
- хоп.

Проведённая аналитическая работа позволила...

В результате работы, проведенной в конструкторском разделе, были приведены... Также была определена схема работы...

Для реализации в качестве используемого языка программирования был выбран Я Π ..., а в качестве среды разработки — ...

В результате работы было...

В ходе выполнения поставленных задач были получены знания в области ..., а также изучены...

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

Список литературы

- 1. Fatal Errors: Linux Process Scheduling-Real-Time Scheduler Learning Notes [Электронный ресурс]. Режим доступа: https://www.fatalerrors.org/a/linux-process-scheduling-real-time-scheduler_learning-notes.html (дата обращения 20.12.2021).
- 2. The Linux Kernel documentation [Электронный ресурс]. Режим доступа: https://www.kernel.org (дата обращения 20.12.2021).
- 3. А. Кирьянов Д. Модель процессов в современных операционных системах и их реализация в ОС Linux // Сервис в России и за рубежом. 2007. № 1.
- 4. Проект Losst [Электронный ресурс]. Режим доступа: https://losst.ru (дата обращения 20.12.2021).
- 5. Programmer All: Linux kernel learning notes (6) [Электронный ресурс]. Режим доступа: https://www.programmerall.com/article/63151049863/(дата обращения 20.12.2021).
- 6. Разработка и внедрение системы на встраиваемом Linux: Планирование процессов [Электронный ресурс]. Режим доступа: http://dmilvdv.narod.ru/Translate/ELSDD/index.html (дата обращения 20.12.2021).
- 7. Проект OpenNET [Электронный ресурс]. Режим доступа: https://www.opennet.ru/opennews/art.shtml?num=38906 (дата обращения 20.12.2021).

ПРИЛОЖЕНИЕ 1

Листинг 9: Структура ядра task struct

```
struct task struct {
     #ifdef CONFIG THREAD INFO IN TASK
2
          * For reasons of header soup (see
4

    current thread info()), this

          * must be the first element of task struct.
5
          */
6
         struct thread info
                                     thread info;
7
    #endif
8
         unsigned int
                                   __state;
10
    #ifdef CONFIG PREEMPT RT
11
         /* saved state for "spinlock sleepers" */
12
         unsigned int
                                 saved state;
13
    #endif
         /*
16
          * This begins the randomizable portion of
17

→ task struct. Only

          * scheduling-critical items should be added above
          \rightarrow here.
          * /
19
         randomized struct fields start
20
21
         void
                               *stack;
         refcount t
                                 usage;
23
         /* Per task flags (PF *), defined further below: */
24
         unsigned int
                                  flags;
25
         unsigned int
                                  ptrace;
26
    #ifdef CONFIG SMP
28
         int
                             on cpu;
29
         struct call single node
                                        wake entry;
         unsigned int
                                 wakee flips;
                                   wakee flip decay ts;
         unsigned long
32
         struct task struct
                                     *last wakee;
33
```

```
34
         /*
35
          * recent used cpu is initially set as the last CPU

→ used by a task

          * that wakes affine another task. Waker/wakee
37

→ relationships can

          * push tasks around a CPU where each wakeup moves to
38
           \rightarrow the next one.
          * Tracking a recently used CPU allows a quick search
39
           → for a recently
          * used CPU that may be idle.
40
          */
41
         int
                              recent used cpu;
42
         int
                              wake cpu;
43
     #endif
44
         int
                              on rq;
45
46
         int
                              prio;
                              static prio;
         int
48
         int
                              normal prio;
49
         unsigned int
                                   rt priority;
50
51
         struct sched entity
                                       se;
         struct sched rt entity
                                         rt;
53
         struct sched dl entity
                                          dl;
54
         const struct sched class
                                      *sched class;
55
     #ifdef CONFIG SCHED CORE
57
         struct rb node
                                     core node;
58
         unsigned long
                                   core cookie;
59
         unsigned int
                                   core occupation;
60
    #endif
62
    #ifdef CONFIG CGROUP SCHED
63
                                    *sched task_group;
         struct task group
64
     #endif
65
    #ifdef CONFIG UCLAMP TASK
67
         /*
68
          * Clamp values requested for a scheduling entity.
69
          * Must be updated with task rq lock() held.
```

```
* /
71
         struct uclamp se uclamp req[UCLAMP CNT];
72
73
          * Effective clamp values used for a scheduling
          \rightarrow entity.
          * Must be updated with task rq lock() held.
75
76
         struct uclamp se
                                 uclamp[UCLAMP CNT];
77
     #endif
78
79
         struct sched statistics
                                   stats;
80
81
     #ifdef CONFIG PREEMPT NOTIFIERS
82
         /* List of struct preempt notifier: */
83
         struct hlist head preempt notifiers;
84
     #endif
85
     #ifdef CONFIG BLK DEV IO TRACE
         unsigned int
                                   btrace seq;
88
     #endif
89
90
         unsigned int
                                  policy;
91
                            nr cpus allowed;
         int
         const cpumask t
                                      *cpus ptr;
93
         cpumask t
                                *user cpus ptr;
94
         cpumask t
                               cpus mask;
95
                               *migration pending;
         void
     #ifdef CONFIG SMP
         unsigned short
                                     migration disabled;
98
     #endif
99
         unsigned short
                                     migration flags;
100
     #ifdef CONFIG PREEMPT RCU
102
                             rcu read lock nesting;
103
         union rcu special
                                 rcu read unlock special;
104
                                rcu node entry;
         struct list head
105
         struct rcu node
                                      *rcu blocked node;
     #endif /* #ifdef CONFIG PREEMPT RCU */
107
108
     #ifdef CONFIG TASKS RCU
109
         unsigned long
                                    rcu tasks nvcsw;
```

```
rcu_tasks holdout;
         u8
111
         118
                              rcu tasks idx;
112
                               rcu tasks idle cpu;
         int
113
         struct list head
                                    rcu tasks holdout list;
     #endif /* #ifdef CONFIG TASKS RCU */
115
116
     #ifdef CONFIG TASKS TRACE RCU
117
         int
                               trc reader nesting;
                               trc ipi to cpu;
         int
119
                                     trc reader special;
         union rcu special
120
                                trc reader checked;
         bool
121
         struct list head
                                    trc holdout list;
122
     #endif /* #ifdef CONFIG TASKS TRACE RCU */
124
         struct sched info
                                    sched info;
125
126
         struct list head
                                    tasks;
127
     #ifdef CONFIG SMP
         struct plist node
                                    pushable tasks;
129
         struct rb node
                                     pushable dl tasks;
130
     #endif
131
132
         struct mm struct
                                    *mm;
                                    *active mm;
         struct mm struct
134
135
         /* Per-thread vma caching: */
136
         struct vmacache
                                       vmacache;
137
     #ifdef SPLIT RSS COUNTING
139
         struct task rss stat
                                        rss stat;
140
     #endif
141
         int
                               exit state;
         int
                               exit code;
143
                               exit signal;
144
         /* The signal sent when the parent dies: */
145
                               pdeath signal;
         int
146
         /* JOBCTL *, siglock protected: */
         unsigned long
                                      jobctl;
148
149
         /* Used for emulating ABI behavior of previous Linux
150
          → versions: */
```

```
unsigned int
                                    personality;
151
152
         /* Scheduler bits, serialized by scheduler locks: */
153
                                sched reset on fork:1;
         unsigned
         unsigned
                                sched contributes to load:1;
155
         unsigned
                                sched migrated:1;
156
     #ifdef CONFIG PSI
157
         unsigned
                                sched psi wake requeue:1;
158
     #endif
159
160
         /* Force alignment to the next boundary: */
161
         unsigned
                                :0;
162
163
         /* Unserialized, strictly 'current' */
164
165
          /*
166
           * This field must not be in the scheduler word above
167
           \rightarrow due to wakelist
           * queueing no longer being serialized by p->on cpu.
168
           → However:
169
           * p \rightarrow XXX = X;
                                      ttwu()
170
           * schedule()
                                        if (p->on rq && ..) //
           → false
             smp mb after spinlock();
172

→ (smp load acquire(&p->on cpu) && //true
           * deactivate task()
173
              ttwu queue wakelist())
               p->on rq = 0;
                                            p->sched remote wakeup
174
             = Y;
175
           * quarantees all stores of 'current' are visible
           → before
           * ->sched remote wakeup gets used, so it can be in
177
           \rightarrow this word.
           * /
178
         unsigned
                                sched remote wakeup:1;
180
         /* Bit to tell LSMs we're in execve(): */
181
         unsigned
                                in execve:1;
182
         unsigned
                                in iowait:1;
```

```
#ifndef TIF RESTORE SIGMASK
184
         unsigned
                               restore sigmask:1;
185
     #endif
186
     #ifdef CONFIG MEMCG
         unsigned
                               in user fault:1;
188
     #endif
189
     #ifdef CONFIG COMPAT BRK
190
         unsigned
                               brk randomized:1;
191
     #endif
192
     #ifdef CONFIG CGROUPS
193
         /* disallow userland-initiated cgroup migration */
194
                     no cgroup migration:1;
         unsigned
195
         /* task is frozen/stopped (used by the cgroup freezer)

→ * /
         unsigned
                               frozen:1;
197
     #endif
198
     #ifdef CONFIG BLK CGROUP
199
         unsigned
                               use memdelay:1;
     #endif
201
     #ifdef CONFIG PSI
202
         /* Stalled due to lack of memory */
203
         unsigned
                              in memstall:1;
204
     #endif
     #ifdef CONFIG PAGE OWNER
206
         /* Used by page owner=on to detect recursion in page
207
          → tracking. */
         unsigned
                              in page owner:1;
208
     #endif
     #ifdef CONFIG EVENTFD
210
         /* Recursion prevention for eventfd signal() */
211
         unsigned
                               in eventfd signal:1;
212
     #endif
213
214
         unsigned long
                                    atomic flags; /* Flags
215
          → requiring atomic access. */
216
         struct restart block restart block;
218
         pid t
                                pid;
219
         pid t
                                tgid;
220
221
```

```
#ifdef CONFIG STACKPROTECTOR
222
         /* Canary value for the -fstack-protector GCC feature:
223
         unsigned long
                                    stack canary;
224
     #endif
225
         /*
226
          * Pointers to the (original) parent process, youngest
227

→ child, younger sibling,

          * older sibling, respectively. (p->father can be
228
           → replaced with
          * p->real parent->pid)
229
230
         /* Real parent process: */
232
         struct task struct rcu *real parent;
233
234
         /* Recipient of SIGCHLD, wait4() reports: */
235
         struct task struct rcu *parent;
237
         /*
238
          * Children/sibling form the list of natural children:
239
          */
240
         struct list head
                                   children;
         struct list head
                                  sibling;
242
         struct task struct
                                    *group leader;
243
244
         /*
245
          * 'ptraced' is the list of tasks this task is using
           \rightarrow ptrace() on.
247
          * This includes both natural children and
248
           → PTRACE ATTACH targets.
          * 'ptrace entry' is this task's link on the
249

    p->parent->ptraced list.

          * /
250
         struct list head
                                  ptraced;
251
         struct list head
                                  ptrace entry;
253
         /* PID/PID hash table linkage. */
254
         struct pid
                                 *thread pid;
255
         struct hlist node
                                   pid links[PIDTYPE MAX];
```

```
struct list head
                                    thread group;
257
          struct list head
                                    thread node;
258
259
                                      *vfork done;
          struct completion
260
261
          /* CLONE CHILD SETTID: */
262
                                   *set child tid;
          int user
263
264
          /* CLONE CHILD CLEARTID: */
265
          int user
                                   *clear child tid;
266
267
          /* PF IO WORKER */
268
                                 *pf io worker;
          void
269
270
          u64
                               utime;
271
          u64
                               stime;
272
     #ifdef CONFIG ARCH HAS SCALED CPUTIME
273
          u64
                               utimescaled;
          u64
                               stimescaled;
275
     #endif
276
          u64
                               gtime;
277
          struct prev cputime
                                        prev cputime;
278
     #ifdef CONFIG VIRT CPU ACCOUNTING GEN
          struct vtime
                                     vtime;
280
     #endif
281
282
     #ifdef CONFIG NO HZ FULL
          atomic t
                                tick dep mask;
     #endif
285
          /* Context switch counts: */
286
          unsigned long
                                      nvcsw;
287
          unsigned long
                                      nivcsw;
289
          /* Monotonic time in nsecs: */
290
          u64
                               start time;
291
292
          /* Boot based time in nsecs: */
          u64
                               start boottime;
294
295
          /* MM fault and swap info: this can arguably be seen
296
          → as either mm-specific or thread-specific: */
```

```
unsigned long
                                  min flt;
297
         unsigned long
                                 maj flt;
298
299
         /* Empty if CONFIG POSIX CPUTIMERS=n */
300
         struct posix cputimers
                                  posix cputimers;
301
302
     #ifdef CONFIG POSIX CPU TIMERS TASK WORK
303
         struct posix cputimers work posix cputimers work;
     #endif
305
306
         /* Process credentials: */
307
308
         /* Tracer's credentials at attach: */
         const struct cred rcu
                                     *ptracer cred;
310
311
         /* Objective and real subjective task credentials
312
         → (COW): */
         const struct cred rcu *real cred;
314
         /* Effective (overridable) subjective task credentials
315
         → (COW): */
         const struct cred rcu
                                  *cred;
316
     #ifdef CONFIG KEYS
318
         /* Cached requested key. */
319
         struct key
                              *cached requested key;
320
     #endif
321
         /*
323
          * executable name, excluding path.
324
325
          * - normally initialized setup new exec()
          * - access it with [gs]et task comm()
327
          * - lock it with task lock()
328
         * /
329
         char
                              comm[TASK COMM LEN];
330
         struct nameidata
                                  *nameidata;
332
333
     #ifdef CONFIG SYSVIPC
334
         struct sysv sem
                                    sysvsem;
```

```
struct sysv shm
                                   sysvshm;
336
    #endif
337
     #ifdef CONFIG DETECT HUNG TASK
338
        unsigned long
                                 last switch count;
        unsigned long
                                 last switch time;
340
     #endif
341
        /* Filesystem information: */
342
        struct fs struct
343
344
        /* Open file information: */
345
        struct files struct
                                   *files;
346
347
    #ifdef CONFIG IO URING
        struct io uring task *io uring;
349
    #endif
350
351
        /* Namespaces: */
352
        struct nsproxy
                                  *nsproxy;
354
        /* Signal handlers: */
355
        struct signal struct
                                *signal;
356
        struct sighand struct rcu
                                           *sighand;
357
        sigset t
                            blocked;
        sigset t
                            real blocked;
359
        /* Restored if set restore sigmask() was used: */
360
        sigset t
                            saved sigmask;
361
        struct sigpending pending;
362
        unsigned long
                                sas ss sp;
        size t
                             sas ss size;
364
        unsigned int
                               sas ss flags;
365
        struct callback head
                                   *task works;
368
    #ifdef CONFIG AUDIT
369
    #ifdef CONFIG AUDITSYSCALL
370
        371
    #endif
        kuid t
                              loginuid;
373
        unsigned int
                                sessionid;
374
     #endif
375
        struct seccomp
                                 seccomp;
```

```
struct syscall user dispatch syscall dispatch;
377
378
         /* Thread group tracking: */
379
         u64
                              parent exec id;
380
         u64
                              self exec id;
381
382
         /* Protection against (de-)allocation: mm, files, fs,
383

→ tty, keyrings, mems allowed, mempolicy: */
         spinlock t
                                  alloc lock;
384
385
         /* Protection of the PI data structures: */
386
         raw spinlock t
                                      pi lock;
387
388
         struct wake q node
                                      wake q;
389
390
     #ifdef CONFIG RT MUTEXES
391
         /* PI waiters blocked on a rt mutex held by this task:
392

→ * /
         struct rb root cached
                                         pi waiters;
393
         /* Updated under owner's pi lock and rq lock */
394
         struct task struct
                                      *pi top task;
395
         /* Deadlock detection and priority inheritance
396
          → handling: */
                                         *pi blocked on;
         struct rt mutex waiter
397
     #endif
398
399
     #ifdef CONFIG DEBUG MUTEXES
         /* Mutex deadlock detection: */
                                *blocked on;
         struct mutex waiter
402
     #endif
403
404
     #ifdef CONFIG DEBUG ATOMIC SLEEP
         int
                              non block count;
406
     #endif
407
408
     #ifdef CONFIG TRACE IRQFLAGS
409
         struct irqtrace events
                                          irqtrace;
         unsigned int
                                    hardirg threaded;
411
         u64
                              hardirq chain key;
412
         int
                              softirqs enabled;
413
         int
                              softirg context;
414
```

```
int
                              irq config;
415
     #endif
416
     #ifdef CONFIG PREEMPT RT
417
         int
                              softirg disable cnt;
     #endif
419
420
     #ifdef CONFIG LOCKDEP
421
     # define MAX LOCK DEPTH
                                           48UL
         u64
                              curr chain key;
         int
                              lockdep depth;
424
         unsigned int
                                   lockdep recursion;
425
         struct held lock
                                   held locks[MAX LOCK DEPTH];
426
     #endif
428
     #if defined(CONFIG UBSAN) && !defined(CONFIG UBSAN TRAP)
429
         unsigned int
                                    in ubsan;
430
     #endif
431
         /* Journalling filesystem info: */
433
                               *journal info;
         void
434
435
         /* Stacked block device info: */
436
         struct bio list
                                       *bio list;
438
         /* Stack plugging: */
439
         struct blk plug
                                       *pluq;
440
441
         /* VM state: */
         struct reclaim state
                                    *reclaim state;
443
444
         struct backing dev info
                                           *backing dev info;
445
         struct io context *io context;
447
448
     #ifdef CONFIG COMPACTION
449
         struct capture control
                                        *capture control;
450
     #endif
         /* Ptrace state: */
452
         unsigned long
                                    ptrace message;
453
         kernel siginfo t
                                 *last siginfo;
454
```

```
struct task io accounting
456
     #ifdef CONFIG PSI
457
         /* Pressure stall state */
458
         unsigned int
                                   psi flags;
     #endif
460
     #ifdef CONFIG TASK XACCT
461
         /* Accumulated RSS usage: */
462
         u64
                              acct rss mem1;
463
         /* Accumulated virtual memory usage: */
464
                              acct vm mem1;
         u64
465
         /* stime + utime since last update: */
466
                             acct timexpd;
467
     #endif
468
     #ifdef CONFIG CPUSETS
469
         /* Protected by ->alloc lock: */
470
                                mems allowed;
         nodemask t
471
         /* Sequence number to catch updates: */
472
         seqcount spinlock t
                                      mems allowed seq;
         int
                              cpuset mem spread rotor;
474
         int
                              cpuset slab spread rotor;
475
     #endif
476
     #ifdef CONFIG CGROUPS
477
         /* Control Group info protected by css set lock: */
         struct css set rcu
                                       *cgroups;
479
         /* cg list protected by css set lock and
480

    tsk->alloc lock: */

         struct list head
                                   cg list;
481
     #endif
     #ifdef CONFIG X86 CPU RESCTRL
483
         u32
                              closid;
484
         1132
                              rmid;
485
     #endif
     #ifdef CONFIG FUTEX
487
         struct robust list head user *robust list;
488
     #ifdef CONFIG COMPAT
489
         struct compat robust list head user
490

    *compat robust list;

     #endif
491
                                   pi state list;
         struct list head
492
         struct futex pi state
                                         *pi state cache;
493
         struct mutex
                                   futex exit mutex;
```

```
unsigned int
                                   futex state;
495
     #endif
496
     #ifdef CONFIG PERF EVENTS
497
         struct
          → perf event context *perf event ctxp[perf nr task dontext
         struct mutex
                                   perf event mutex;
499
         struct list head
                                   perf event list;
500
     #endif
501
     #ifdef CONFIG DEBUG PREEMPT
502
         unsigned long
                                   preempt disable ip;
503
     #endif
504
     #ifdef CONFIG NUMA
505
         /* Protected by alloc lock: */
         struct mempolicy
                                  *mempolicy;
         short
                                il prev;
508
         short
                                pref node fork;
509
     #endif
510
     #ifdef CONFIG NUMA BALANCING
         int
                              numa scan seq;
512
         unsigned int
                                  numa scan period;
513
         unsigned int
                                  numa scan period max;
514
         int
                             numa preferred nid;
515
         unsigned long
                                    numa migrate retry;
516
         /* Migration stamp: */
517
         u64
                              node stamp;
518
         u64
                              last task numa placement;
519
         u64
                              last sum exec runtime;
520
         struct callback head
                                       numa work;
522
         /*
523
          * This pointer is only modified for current in
524

→ syscall and

          * pagefault context (and for tasks being destroyed),
525
           → so it can be read
          * from any of the following contexts:
526
          * - RCU read-side critical section
527
          * - current->numa group from everywhere
          * - task's runqueue locked, task not running
529
          * /
530
         struct numa group rcu
                                          *numa group;
531
532
```

```
533
           * numa faults is an array split into four regions:
534
           * faults memory, faults cpu, faults memory buffer,
535
           → faults cpu buffer
           * in this precise order.
536
537
           * faults memory: Exponential decaying average of
538
            \rightarrow faults on a per-node
           * basis. Scheduling placement decisions are made
539
           \rightarrow based on these
           * counts. The values remain static for the duration
540
           \rightarrow of a PTE scan.
           * faults cpu: Track the nodes the process was running
           \hookrightarrow on when a NUMA
           * hinting fault was incurred.
542
           * faults memory buffer and faults cpu buffer: Record
543
            \rightarrow faults per node
           * during the current scan window. When the scan
           \hookrightarrow completes, the counts
           * in faults memory and faults cpu decay and these
545
            → values are copied.
           */
546
          unsigned long
                                     *numa faults;
547
         unsigned long
                                      total numa faults;
548
549
          /*
550
           * numa faults locality tracks if faults recorded

    during the last

           * scan window were remote/local or failed to migrate.
552
           \hookrightarrow The task scan
           * period is adapted based on the locality of the
553

→ faults with different

           * weights depending on whether they were shared or
554
            → private faults
           * /
555
         unsigned long
                                     numa faults locality[3];
556
         unsigned long
                                      numa pages migrated;
558
     #endif /* CONFIG NUMA BALANCING */
559
560
     #ifdef CONFIG RSEQ
```

```
struct rseq __user *rseq;
562
          u32 rseq sig;
563
          /*
           * RmW on rseq event mask must be performed atomically
565
           * with respect to preemption.
566
           * /
567
          unsigned long rseq event mask;
568
     #endif
569
570
          struct tlbflush unmap batch tlb ubc;
571
572
          union {
573
              refcount t
                                 rcu users;
              struct rcu head
                                         rcu;
575
          };
576
577
          /* Cache last used pipe for splice(): */
578
          struct pipe inode info
                                            *splice pipe;
580
          struct page frag
                                     task frag;
581
582
     #ifdef CONFIG TASK DELAY ACCT
583
          struct task delay info
                                           *delays;
584
     #endif
585
586
     #ifdef CONFIG FAULT INJECTION
587
          int
                               make it fail;
          unsigned int
                                     fail nth;
589
     #endif
590
          /*
591
           * When (nr dirtied >= nr dirtied pause), it's time to
592
           \hookrightarrow call
           * balance dirty pages() for a dirty throttling pause:
593
           * /
594
                               nr dirtied;
          int
595
                               nr dirtied pause;
          int
596
          /* Start of a write-and-pause period: */
          unsigned long
                                      dirty paused when;
598
599
     #ifdef CONFIG LATENCYTOP
600
          int
                                latency record count;
601
```

```
struct
602
                                      latency record[LT SAVECOUNT];
          → latency record
     #endif
603
         /*
          * Time slack values; these are used to round up
605
           \rightarrow poll() and
          * select() etc timeout values. These are in
606
             nanoseconds.
          */
607
                              timer slack ns;
         u64
608
         u64
                              default timer slack ns;
609
610
     #if defined(CONFIG KASAN GENERIC) ||

→ defined(CONFIG KASAN SW TAGS)

         unsigned int
                                    kasan depth;
612
     #endif
613
614
     #ifdef CONFIG KCSAN
         struct kcsan ctx
                                   kcsan ctx;
616
     #ifdef CONFIG TRACE IRQFLAGS
617
         struct irqtrace events
                                    kcsan save irqtrace;
618
     #endif
619
     #endif
620
621
     #if IS ENABLED (CONFIG KUNIT)
622
         struct kunit
                                    *kunit test;
623
     #endif
624
     #ifdef CONFIG FUNCTION GRAPH TRACER
626
         /* Index of current stored address in ret stack: */
627
         int
                              curr ret stack;
628
         int
                              curr ret depth;
629
630
         /* Stack of return addresses for return function
631
          → tracing: */
         struct ftrace ret stack
                                          *ret stack;
632
         /* Timestamp for last schedule: */
634
         unsigned long long ftrace timestamp;
635
636
         /*
637
```

```
* Number of functions that haven't been traced
638
           * because of depth overrun:
639
           * /
640
         atomic t
                                trace overrun;
642
          /* Pause tracing: */
643
         atomic t
                                tracing graph pause;
644
     #endif
645
646
     #ifdef CONFIG TRACING
647
          /* State flags for use by tracers: */
648
         unsigned long
                                      trace;
649
650
          /* Bitmask and counter of trace recursion: */
651
         unsigned long
                                     trace recursion;
652
     #endif /* CONFIG TRACING */
653
     #ifdef CONFIG KCOV
          /* See kernel/kcov.c for more details. */
656
657
          /* Coverage collection mode enabled for this task (0
658

    if disabled): */
         unsigned int
                                    kcov mode;
659
660
         /* Size of the kcov area: */
661
         unsigned int
                                    kcov size;
662
          /* Buffer for coverage collection: */
                                *kcov area;
         void
665
666
          /* KCOV descriptor wired with this task or NULL: */
667
         struct kcov
                                   *kcov;
669
          /* KCOV common handle for remote coverage collection:
670
                               kcov handle;
         u64
671
          /* KCOV sequence number: */
673
         int
                               kcov sequence;
674
675
          /* Collect coverage from softirg context: */
```

```
unsigned int
                                 kcov softirq;
677
     #endif
678
679
     #ifdef CONFIG MEMCG
         struct mem cgroup
                                   *memcg in oom;
681
         gfp t
                              memcg oom gfp mask;
682
         int
                             memcg oom order;
683
684
         /* Number of pages to reclaim on returning to
685
         → userland: */
         unsigned int
                                  memcg nr pages over high;
686
687
         /* Used by memcontrol for targeted memcg charge: */
         struct mem cgroup
                               *active memcg;
689
     #endif
690
691
     #ifdef CONFIG BLK CGROUP
         struct request queue *throttle queue;
     #endif
694
695
     #ifdef CONFIG UPROBES
696
         struct uprobe task *utask;
697
     #endif
     #if defined(CONFIG BCACHE) | |
699

→ defined(CONFIG BCACHE MODULE)

         unsigned int
                                 sequential io;
700
         unsigned int
                                  sequential io avg;
     #endif
         struct kmap ctrl
                                  kmap ctrl;
703
     #ifdef CONFIG DEBUG ATOMIC SLEEP
704
         unsigned long
                                   task state change;
705
     # ifdef CONFIG PREEMPT RT
         unsigned long
                                  saved state change;
707
     # endif
708
     #endif
709
                            pagefault disabled;
         int
710
     #ifdef CONFIG MMU
         struct task struct
                                  *oom reaper list;
712
     #endif
713
     #ifdef CONFIG VMAP_STACK
         struct vm struct
                                 *stack vm area;
```

```
#endif
716
     #ifdef CONFIG THREAD INFO IN TASK
717
         /* A live task holds one reference: */
718
         refcount t
                                stack refcount;
     #endif
720
     #ifdef CONFIG LIVEPATCH
721
         int patch state;
722
     #endif
723
     #ifdef CONFIG SECURITY
         /* Used by LSM modules for access restriction: */
725
                               *security;
726
     #endif
727
     #ifdef CONFIG BPF SYSCALL
         /* Used by BPF task local storage */
729
         struct bpf local storage rcu *bpf storage;
730
         /* Used for BPF run context */
731
         struct bpf run ctx *bpf ctx;
732
     #endif
734
     #ifdef CONFIG GCC PLUGIN STACKLEAK
735
         unsigned long
                                    lowest stack;
736
         unsigned long
                                    prev lowest stack;
737
     #endif
739
     #ifdef CONFIG X86 MCE
740
         void user
                                 *mce vaddr;
741
         __u64
                               mce kflags;
         u64
                              mce addr;
                                mce ripv : 1,
         u64
744
                          mce whole page : 1,
745
                           mce reserved : 62;
746
         struct callback head
                                      mce kill me;
         int
                             mce count;
748
     #endif
749
750
     #ifdef CONFIG KRETPROBES
751
         struct llist head
                                            kretprobe instances;
     #endif
753
754
     #ifdef CONFIG ARCH HAS PARANOID L1D FLUSH
755
         /*
```

```
* If L1D flush is supported on mm context switch
757
           * then we use this callback head to queue kill work
758
          * to kill tasks that are not running on SMT disabled
759
          * cores
760
          */
761
          struct callback head
                                        lld flush kill;
762
     #endif
763
          /*
765
          * New fields for task struct should be added above
766
           \rightarrow here, so that
           * they are included in the randomized portion of
767

→ task struct.

           */
768
         randomized struct fields end
769
770
          /* CPU-specific state of this task: */
771
          struct thread struct
                                        thread;
773
          /*
774
           * WARNING: on x86, 'thread struct' contains a
775
           → variable-sized
           * structure. It *MUST* be at the end of
           → 'task struct'.
777
           * Do not put anything below here!
778
           */
779
     };
780
```